


占位符



2025大模型训练与推理 硬件采购及配置指南

九天Hector

大模型&深度学习技术入门**第一关**

配置硬件

- 我有预算XX，应该**买什么样的显卡&配置什么样的服务器？**
- 个人学习和实验环境**推荐什么样配置？**
- 运行大模型购买**哪种GPU最划算？ Mac M系列芯片运行大模型么？**
- 我们公司需要部署**70B的大模型**，推理和微调**需要什么服务器配置？**
- 运行大模型，**CPU、内存、硬盘、散热**应该如何考虑？
- 没有**NVLink**，如何配置单机多卡？**国产GPU**的大模型运行性能如何？**分布式模型推理和训练应该如何完成...**

深度学习&大模型训练与推理

硬件配置指南

content



占位符

- Part 1.读懂GPU性能: GPU性能核心参数介绍
- Part 2.现阶段主流显卡 (从2080到H100) 性能分析
- Part 3.各类大模型推理、微调、预训练所需显存
- Part 4.从个人实验到70B模型推理, 各类场景下硬件配置方案推荐

公开课附赠独家硬件配置指南表

- ✓ 显卡性能排名表
- ✓ 各参数大模型训练所需硬件表
- ✓ 显卡性价比排名表
- ✓ 各参数大模型微调&推理硬件表
- ✓ 热门显卡参数对比表
- ✓ 不同需求下硬件配置表

占位符



>> 扫码添加课程助教 <<
回复LLM领完整公开课资料

占位符

读懂显卡参数，GPU核心性能参数介绍

常见的显卡介绍



占位符

- RTX系列显卡的**游戏性能：一分钱一分货**。但是大模型方面的计算性能却并非如此。
- 例如4090游戏性能几乎是3090的两倍，但若换算为**单位人民币可以买到的大模型训练性能，3090是4090的1.5倍**；

Datasheet



NVIDIA DGX H200

The gold standard for AI infrastructure.

Artificial intelligence has become the go-to approach for solving difficult business challenges. Whether improving customer service, optimizing supply chains, extracting business intelligence, or designing leading-edge products and services with generative AI and other transformer models, AI gives organizations across nearly every industry the mechanism to realize innovation. And as a pioneer in AI infrastructure, NVIDIA DGX™ provides the most powerful and complete AI platform for bringing these essential ideas to fruition.


NVIDIA DGX H200 powers business innovation and optimization. As a part of NVIDIA's legendary **DGX platform** and the foundation of **NVIDIA DGX SuperPOD™** and **DGX BasePOD™**, DGX H200 is an AI powerhouse that features the groundbreaking **NVIDIA H200 Tensor Core GPU**. The system is designed to maximize AI throughput, providing enterprises with a highly refined, systemized, and scalable platform to help them achieve breakthroughs in natural language processing, recommender systems, data analytics, and much more. Available on-premises and through a wide variety of access and deployment options, DGX H200 delivers the performance needed for enterprises to solve the biggest challenges with AI.

The Cornerstone of Your AI Center of Excellence

AI has bridged the gap between science and business. No longer the domain of experimentation, AI is used day in and day out by companies large and small to fuel their innovation and optimize their business. As a part of the world's first purpose-built AI infrastructure portfolio, DGX H200 is designed to be the centerpiece of an enterprise AI center of excellence. It's a fully optimized hardware and software platform that includes **NVIDIA Enterprise Support** for the new range of NVIDIA AI software solutions, a rich ecosystem of third-party support, and access to expert advice from NVIDIA specialists, allowing organizations to solve the biggest and most complex business problems with AI. DGX H200 offers proven reliability, with the DGX platform being used by thousands of customers around the world spanning nearly every industry.

Break Through the Barriers to AI at Scale

NVIDIA DGX H200 breaks the limits of AI scale and performance. It delivers 32 petaFLOPS of AI performance, 2X faster networking than DGX A100 with NVIDIA ConnectX®-7 smart network interface cards (SmartNICs), and high-speed scalability for NVIDIA DGX SuperPOD and DGX BasePOD. DGX H200 is supercharged with



Specifications	
GPU	8x NVIDIA H200 Tensor Core GPUs, with 141GB of GPU memory each
GPU memory	1,128GB total
Performance	32 petaFLOPS FP8
NVIDIA NVSwitch™	4x
System power usage	10.2kW max*
CPU	Dual Intel® Xeon® Platinum 8480C Processors 112 Cores total, 2.00 GHz (Base), 3.80 GHz (Max Boost)
System memory	2TB
Networking	4x OSFP ports serving 8x single-port NVIDIA ConnectX-7 VPI ➤ Up to 400Gb/s InfiniBand/Ethernet 2x dual-port QSFP112 NVIDIA ConnectX-7 VPI ➤ Up to 400Gb/s InfiniBand/Ethernet
Management network	10Gb/s onboard NIC with RJ45 100Gb/s Ethernet NIC Host baseboard management controller (BMC) with RJ45
Storage	OS: 2x 1.92TB NVMe M.2
Internal storage:	8x 3.84TB NVMe U.2
Software	NVIDIA AI Enterprise – Optimized AI software NVIDIA Base Command – Orchestration, scheduling, and cluster management DGX OS / Ubuntu / Red Hat Enterprise Linux / Rocky – Operating System
Support	Comes with 3-year business-standard hardware and software support
System weight	287.6lbs (130.45kgs)
Packaged weight	376lbs (170.45kgs)
System dimensions	Height: 14.0in (356mm) Width: 19.0in (482.2mm) Length: 35.3in (897.1mm)
Operating temperature range	5–30°C (41–86°F)

*10.2kW for standard configuration. DGX H200 CTS (Custom Thermal Solution) supports up to 14.3kW.

占位符

GPU计算性能核心参数

- **CUDA Cores**: CUDA核心
- **Tensor Cores**: 张量计算核心
- **GPU Memory**: 显存
- **FLOPS**: 每秒浮点计算次数
- **NVLink&NVSwitch**: 显卡桥接
- **TDP**: 最大功耗需求

GPU计算性能核心参数

详细介绍

- **CUDA Cores**: CUDA核心，是 NVIDIA GPU 的基础计算单元，负责执行并行计算任务；
- **Tensor Cores**: 张量计算核心，是专门设计用于矩阵运算的硬件单元，核心任务是加速矩阵乘法，特别是用于深度学习的张量运算，其中20系显卡开始加入张量核心；
- **GPU Memory**: 显存，决定了可以加载的模型大小、数据批量（Batch Size）以及中间激活值存储，显存不足会限制任务规模，甚至导致程序崩溃；
- **FLOPS**: 每秒浮点计算次数，是衡量 GPU 浮点运算性能的单位，代表GPU的理论性能；
- **NVLink&NVSwitch**: 显卡桥接技术，30系显卡取消了NVLink，替代方案是PCIE，目前NVLink只用于企业级图形显卡；

PCIe、NVLink与NVSwitch

技术方案介绍介绍与对比

占位符

特性	PCIe	NVLink	NVSwitch
主要用途	通用互联接口，连接 GPU、CPU、SSD 等设备	GPU-GPU 或 GPU-CPU 的高速互联	多 GPU 系统的全互联，实现 GPU 间直接通信
连接设备数量	理论无限制，但共享总带宽	通常最多 8 块 GPU	支持 16 GPU 以上的全互联
单连接带宽（双向）	PCIe 4.0: 32GB/s PCIe 5.0: 64GB/s	NVLink 3.0 (A100): 600GB/s NVLink 4.0 (H100): 900GB/s	7.2TB/s (H100 集群内部的总带宽)
延迟	相对较高（受制于主板总线和 CPU 调度）	较低，GPU-GPU 间直接通信	更低，支持多 GPU 高效协作
拓扑结构	树形结构	点对点互联（可链式或星型）	多 GPU 全互联
适用范围	通用，支持所有扩展设备	NVIDIA GPU 专用	高端 GPU 集群（如 DGX 系列）
成本	主板自带，无额外费用	需要 NVLink Bridge，成本较高	集成于 DGX 系列服务器，需配套硬件
典型应用场景	单机小规模 GPU 系统或通用计算	深度学习分布式训练、GPU 高效协作	超大规模分布式集群（16+ GPU，全互联任务）

RTX显卡信息

NVIDIA Gaming Graphics Cards

占位符

Graphics Cards



GeForce RTX 40 Series

[Learn More](#)



GeForce RTX 30 Series

[Learn More](#)

 NVIDIA GeForce RTX 4060 Ti > Boost Clock Speed: 2.54 GHz > GPU Memory Size: 8 GB \$399.00 \$499.00 Save \$100 Add to Cart	Special Offer  ASUS ROG Strix GeForce RTX 4070 SUPER 12GB GDDR6X... > Boost Clock Speed: 2670 MHz > GPU Memory Size: 12GB \$759.99 Add to Cart
 MSI GeForce RTX 4060 VENTUS 2X BLACK 8G OC > Boost Clock Speed: 2490 MHz > GPU Memory Size: 8GB \$299.00 \$314.99 Save \$16 Buy Now	 GIGABYTE WINDFORCE GeForce RTX 4070 12GB > Boost Clock Speed: 2610 MHz > GPU Memory Size: 12GB \$549.99 \$616.74 Save \$67 Buy Now

英伟达官网地址：<https://www.nvidia.com/en-us/geforce/graphics-cards/>

参数类别	RTX 4090	RTX 3090
架构	Ada Lovelace (第五代架构)	Ampere (第四代架构)
CUDA Core 数量	16,384 个	10,496 个
Tensor Core 数量	512 个 (第四代 Tensor Core)	328 个 (第三代 Tensor Core)
RT Core 数量	128 个 (第三代 RT Core)	82 个 (第二代 RT Core)
显存容量	24 GB GDDR6X	24 GB GDDR6X
显存带宽	1,008 GB/s	936 GB/s
显存位宽	384-bit	384-bit
理论 FP32 性能	83.0 TFLOPS	35.6 TFLOPS
理论 Tensor 性能	1,321 TFLOPS (FP16)	285 TFLOPS (FP16)
TDP (热设计功耗)	450W	350W
NVLink 支持	不支持	不支持
PCIe 接口	PCIe 4.0	PCIe 4.0
推荐电源需求	850W 或以上	750W 或以上
芯片制造工艺	TSMC 4nm	Samsung 8nm
发布价格	\$1,599 USD	\$1,499 USD
发布年份	2022 年	2020 年

占位符

3090 vs 4090显卡核心参数对比

- **CUDA Cores**: 增加了56%
- **Tensor Cores**: 提升了4.6倍
- **显存带宽**: RTX 4090 带宽更高 (1,008 GB/s vs 936 GB/s)
- **RTX 4090 的第四代 Tensor Core 引入 FP8 支持, 更适合低精度推理任务。**

A100 PCIe&SXM、A800

显卡参数对比

占位符

参数类别	A100 PCIe	A100 SXM	A800
架构	Ampere	Ampere	Ampere
CUDA Core 数量	6,912 个	6,912 个	6,912 个
Tensor Core 数量	432 个 (第三代 Tensor Core)	432 个 (第三代 Tensor Core)	432 个 (第三代 Tensor Core)
显存容量	40 GB 或 80 GB HBM2e	40 GB 或 80 GB HBM2e	80 GB HBM2e
显存带宽	1,555 GB/s (80 GB 版本)	1,555 GB/s (80 GB 版本)	1,330 GB/s
FP64 性能	9.7 TFLOPS	9.7 TFLOPS	9.7 TFLOPS
FP32 性能	19.5 TFLOPS	19.5 TFLOPS	19.5 TFLOPS
FP16/BF16 性能	312 TFLOPS	312 TFLOPS	312 TFLOPS
FP8 性能	不支持	不支持	不支持
NVLink 支持	不支持	支持 (600GB/s 双向)	支持 (400GB/s 双向)
TDP (热设计功耗)	250W	400W	300W
接口类型	PCIe 4.0	SXM4 (板载插槽)	SXM4 (板载插槽)
目标市场	工作站、小型服务器	数据中心、高性能计算	数据中心 (出口限制版本)

- **A800是A100的“中国特供版”，在显存带宽和NVLink带宽上有所限制；**
- **其他参数都一样，两类卡性能差异不超过20%。**

占位符

读懂显卡参数

Datasheet



NVIDIA H200 Tensor Core GPU

The world's most powerful GPU for supercharging AI and HPC workloads.

Higher Performance and Larger, Faster Memory

The NVIDIA H200 Tensor Core GPU supercharges generative AI and high-performance computing (HPC) workloads with game-changing performance and memory capabilities.

Based on the **NVIDIA Hopper™ architecture**, the NVIDIA H200 is the first GPU to offer 141 gigabytes (GB) of HBM3e memory at 4.8 terabytes per second (TB/s)—that's nearly double the capacity of the **NVIDIA H100 Tensor Core GPU** with 1.4X more memory bandwidth. The H200's larger and faster memory accelerates generative AI

Key Features

- > 141GB of HBM3e GPU memory
- > 4.8TB/s of memory bandwidth
- > 4 petaFLOPS of FP8 performance
- > 2X LLM inference performance



Data Sheet

NVIDIA H200 Tensor Core GPU Datasheet

Datasheet



NVIDIA H100 Tensor Core GPU


Unprecedented performance, scalability, and security for every data center.

Take an Order-of-Magnitude Leap for Accelerated Computing

The NVIDIA H100 Tensor Core GPU delivers unprecedented performance, scalability, and security for every workload. With NVIDIA® NVLink® Switch System, up to 256 H100 GPUs can be connected to accelerate exascale workloads, while the dedicated Transformer Engine supports trillion-parameter language models. H100 uses breakthrough innovations in the NVIDIA Hopper™ architecture to deliver industry-

Accelerate Every Workload, Everywhere

The NVIDIA H100 is an integral part of the NVIDIA data center platform. Built for AI, HPC, and data analytics, the platform accelerates



Data Sheet

NVIDIA H100 Tensor Core GPU Datasheet

Datasheet



NVIDIA L4 Tensor Core GPU

The breakthrough universal accelerator for efficient video, AI, and graphics.

Accelerate Video, AI, and Graphics Workloads

The NVIDIA Ada Lovelace L4 Tensor Core GPU delivers universal acceleration and energy efficiency for video, AI, virtualized desktop, and graphics applications in the enterprise, in the cloud, and at the edge. With NVIDIA's AI platform and full-stack approach, L4 is optimized for inference at scale for a broad range of AI applications, including recommendations, voice-based AI avatar assistants, generative AI, visual search, and contact center automation to deliver the best personalized experiences.

Specifications

FP32	30.3 teraFLOPs
TF32 Tensor Core	120 teraFLOPs*
FP16 Tensor Core	242 teraFLOPs*
BFLOAT16 Tensor Core	242 teraFLOPs*



Data Sheet

NVIDIA L4 Tensor Core GPU Datasheet

Datasheet



NVIDIA L40S

Unparalleled AI and graphics performance for the data center.

Generative AI is fueling transformative change, unlocking a new frontier of opportunities for enterprises across every industry. To transform with AI, enterprises need more compute resources, greater scale, and a broad set of capabilities to meet the demands of an ever-increasing set of diverse and complex workloads.

The NVIDIA L40S GPU is the most powerful universal GPU for the data center, delivering end-to-end acceleration for the next generation of AI-enabled applications—from **generative AI** and model training and inference to 3D graphics, rendering, and video applications.

Accelerate Next-Generation Workloads

- > Generative AI
- > Large language model (LLM) training and inference
- > NVIDIA Omniverse™ Enterprise



Data Sheet

NVIDIA L40S GPU Datasheet

Datasheet



NVIDIA L40

Delivering Unprecedented Visual Computing Performance for the Data Center.

From virtual workstation application to large-scale modeling and simulation, modern visual computing and scientific workflows are growing in both complexity and quantity. Enterprises need data center technology that can deliver extreme performance and scale with versatile capabilities to conquer the diverse computing demands of these increasingly complex workloads.

Fourth-generation Tensor Cores

Hardware support for structural sparsity and optimized TF32 format provides out-of-the-box performance gains for faster AI and data science model training. Accelerate AI-enhanced graphics capabilities, including **DLSS**, delivering upscaled resolution with better performance in select applications.



Data Sheet

NVIDIA L40 GPU Datasheet

Datasheet



NVIDIA GH200 Grace Hopper Superchip


The breakthrough accelerated CPU for large-scale AI and high-performance computing (HPC) applications.

The World's Most Versatile Computing Platform

The NVIDIA Grace Hopper™ architecture brings together the groundbreaking performance of the NVIDIA Hopper™ GPU with the versatility of the NVIDIA Grace™ CPU in a single superchip, connected with the high-bandwidth, memory-coherent NVIDIA® NVLink® Chip-2-Chip (C2C) interconnect.

Key Features

- > 72-core NVIDIA Grace CPU
- > NVIDIA H100 Tensor Core GPU
- > Up to 480GB of LPDDR5X



Data Sheet

NVIDIA A100 Tensor Core GPU Datasheet

NVIDIA显卡介绍列表：<https://resources.nvidia.com/l/en-us-gpu?ncid=no-ncid>

占位符

认识目前主流显卡，NVIDIA主流显卡命名规则

NVIDIA显卡主要分类及命名规则


占位符

类别	主要系列	应用场景	典型显卡	诞生时间
消费级显卡	RTX 系列 (20/30/40)	游戏、图形渲染、轻量级深度学习、AI 推理	RTX 3090、RTX 4090	2018 年 (RTX 20)
数据中心显卡	A 系列 (原版)	大规模深度学习训练、推理、高性能计算 (HPC)	A100、A10、A4	2020 年 (Ampere)
数据中心显卡 (特供)	A800、H800 系列	针对中国市场的特供显卡，调整性能以符合出口限制	A800、H800	2021 年 (A800)
高端数据中心显卡	H 系列 (原版)	超大规模深度学习训练、推理、低精度计算 (FP8)	H100、H200	2022 年 (Hopper)
专业图形显卡	L 系列	数据可视化、AI 推理、工作站任务	L40、L20、L4	2022 年 (Ada)
入门级数据中心显卡	T 系列	云推理服务、虚拟化工作站、轻量化 AI 推理任务	T4	2018 年 (Turing)

NVIDIA各类显卡功能说明

1. RTX 系列 (消费级)

- 设计目标：面向消费者，优化游戏、图形渲染，同时具备基础 AI 加速功能。
- 主要功能：
 - 光线追踪 (RT Core)：优化图形渲染和实时光线追踪。
 - Tensor Core：支持轻量深度学习和推理任务。
- 典型显卡：
 - RTX 3090/4090：性能强大的消费级显卡，适合游戏和中小规模深度学习。
- 适用场景：游戏开发、轻量深度学习、图形渲染。



>> 扫码添加**课程助教** <<
回复**LLM**领完整公开课资料


占位符

NVIDIA各类显卡功能说明

2. A 系列 (数据中心, 原版)

- **设计目标:** 专为大规模深度学习训练和推理设计, 适合数据中心和高性能计算。
- **主要功能:**
 - **HBM2e 高带宽显存:** 提供更高的数据吞吐能力。
 - **Tensor Core:** 优化矩阵计算, 适合深度学习模型的训练和推理。
- **典型显卡:**
 - **A100:** 支持大模型训练和分布式深度学习。
 - **A10/A4:** 性能稍低, 适合中小规模任务。
- **适用场景:** 深度学习训练、高性能计算 (HPC)。

占位符




>> 扫码添加**课程助教** <<
回复**LLM**领完整公开课资料

NVIDIA各类显卡功能说明

4. H 系列（数据中心，高端，原版）

- **设计目标：** NVIDIA 的最高性能显卡系列，面向超大规模深度学习训练和推理任务。
- **主要功能：**
 - **第四代 Tensor Core：** 支持低精度 FP8 和高效的分布式训练。
 - **HBM3 显存：** 显存带宽更高，达到 **2,000 GB/s (H100)** 或更高 (H200)。
 - **NVLink 和 NVSwitch：** 实现多 GPU 的全互联。
- **典型显卡：**
 - **H100：** 支持 GPT-3/GPT-4 等超大模型训练。
 - **H200：** 性能进一步提升，适合更复杂的任务。
- **适用场景：** 超大规模 AI 模型的分布式训练、推理和 HPC。

占位符




>> 扫码添加**课程助教** <<
回复**LLM**领完整公开课资料

NVIDIA各类显卡功能说明

3. A800 和 H800 系列（数据中心，特供）

- **设计目标：** 针对中国市场的特供版显卡，性能略低于原版以符合出口管制。
- **主要功能：**
 - **降低 NVLink 和显存带宽：** 符合国际出口限制。
 - **保持核心计算能力：** CUDA 核心和 Tensor Core 数量保持不变。
- **典型显卡：**
 - **A800：** 面向训练和推理，性能接近 A100。
 - **H800：** 面向大规模深度学习任务，接近 H100 性能。
- **适用场景：** 中国市场的大规模 AI 训练与推理。

占位符




>> 扫码添加**课程助教** <<
回复**LLM**领完整公开课资料

NVIDIA各类显卡功能说明

5. L 系列（专业图形）

- 设计目标：专业图形显卡，适合 AI 推理、数据可视化和图形工作站任务。
- 主要功能：
 - 高显存容量：适合需要大数据吞吐的 AI 和可视化任务。
 - 能效优化：适合数据中心的高效部署。
- 典型显卡：
 - L40：面向中国市场的专业显卡，适合推理任务。
 - L20：性能略低的版本，适合轻量任务。
- 适用场景：AI 推理、虚拟化工作站、数据可视化。

占位符




>> 扫码添加**课程助教** <<
回复**LLM**领完整公开课资料

NVIDIA各类显卡功能说明

6. T 系列 (入门级数据中心)

- 设计目标： 针对低功耗应用场景，适合大规模部署。
- 主要功能：
 - 低功耗设计： 功耗通常低于 70W，适合节能型数据中心。
 - 推理优化： 性能足够支持轻量推理任务。
- 典型显卡：
 - T4： 云推理和虚拟化工作站的主力显卡。
- 适用场景： 轻量推理、虚拟化桌面环境。


占位符



>> 扫码添加**课程助教** <<
回复**LLM**领完整公开课资料

NVIDIA各类显卡功能总结

系列	主要特点	典型用户
RTX	面向消费级市场，兼顾游戏、图形渲染和轻量深度学习任务。	游戏玩家、AI 初学者
A 系列	高性能训练和推理显卡，适合大规模深度学习训练。	数据中心、AI 研究团队
A800	A 系列的特供版，性能略低但适合中国市场。	中国市场的大模型训练和推理
H 系列	NVIDIA 的高端显卡，支持超大规模模型训练（如 GPT-3/4）。	超大规模 AI 项目、HPC 任务
H800	H 系列的特供版，性能略低但适合中国市场。	中国市场的大模型训练和推理
L 系列	专业图形和推理显卡，适合数据可视化和轻量推理任务。	数据分析师、工作站用户
T 系列	入门级显卡，低功耗，适合推理和虚拟化任务。	节能型数据中心、云服务



>> 扫码添加**课程助教** <<
回复**LLM**领完整公开课资料

占位符

目前主流GPU大模型推理与训练性能比较

主流GPU性能对比

- 说明：
- 不区分数据中心显卡和消费级显卡；
 - 不区分原版显卡与中国特供版显卡；
 - 统计信息截止到H100系列显卡；
 - 显卡性能受架构、核心数、带宽等综合影响；



占位符



单卡推理&训练性能



与

每1块钱能买到的最大算力



Relative Performance

■ 16-bit Training ■ 16-bit Inference ■ 8-bit Inference



>> 扫码添加**课程助教**

>> 回复**LLM**领取高清原图



不同显卡性能对比

重要结论

- **H系列显卡性能**在训练以及各精度训练方面**大幅领先**；
- **4090推理性能很强**（强于A100），但训练能力不如A100，且受限于显存大小和显存带宽，**整体训练能力较弱**；
- **3090的推理和训练的理论性能**越是A100的60%，但同样受限于显存大小和显存带宽，实际性能和A100差距较大，但仍不失为低成本模型训练；
- **A10、T4等显卡**在深度学习推理与训练方面表现较差；

Relative Performance per US Dollar

■ 16-bit Training ■ 16-bit Inference ■ 8-bit Inference



>> 扫码添加**课程助教**
>> 回复**LLM**领取高清原图

显卡性价比对比

重要结论

占位符


- 上述对比**未考虑显卡本身运行稳定性与多卡集群带来的性能损耗**，只用于在绝对环境下单卡性能对比；
- 单卡环境下，**4080（16G）是性价比之王**。但在集群环境下，考虑到数据传输损耗和集群运行稳定性，A100/H100仍是首选；
- 2080ti 22G魔改版（约2400元）性价比超越4080，但**使用有一定风险**；
- 除了考虑集群架构外，还需要综合考虑旧版GPU在软件上的一些不适配问题。综合来看，从性价比角度考虑，推荐**2080ti 22G>4080>3090>4090>2080 11G**。

占位符

不同参数量的大模型
训练、微调、推理分别**需要多大显存**

不同尺寸、不同精度 大模型推理所需显存占用

精度	7B (GB)	13B (GB)	30B (GB)	70B (GB)	110B (GB)
FP16	12	24	60	120	200
INT8	8	16	40	80	140
INT4	6	12	24	48	72
INT2	4	8	16	32	48




>> 扫码添加**课程助教** <<
回复**LLM**领完整公开课资料

不同尺寸、不同精度 大模型训练与微调所需显存占用

占位符

方法 / 精度	7B (GB)	13B (GB)	30B (GB)	70B (GB)	110B (GB)
Full (AMP)	120	240	600	1200	2000
Full (FP16)	60	120	300	600	900
Freeze (FP16)	20	40	80	200	360
LoRA (FP16)	16	32	64	160	240
QLoRA (INT8)	10	20	40	80	140
QLoRA (INT4)	6	12	24	48	72



>> 扫码添加**课程助教** <<
回复**LLM**领完整公开课资料

占位符

不同尺寸、不同精度 大模型推理推荐GPU

- 其中RTX 4090可等价替换为RTX 3090；
- 其中A100可替换为A800（国内特供）；
- 其中L40可替换为L20（国内特供）；

模型尺寸	精度	显存需求 (GB)	推荐显卡
7B	FP16	12	RTX 4080 / RTX 4090
	INT8	8	RTX 4080 / T4
	INT4	6	RTX 4080 / RTX 3060
	INT2	4	RTX 3060 / RTX 4080
13B	FP16	24	RTX 4090
	INT8	16	RTX 4090
	INT4	12	RTX 4090 / RTX 4080
	INT2	8	RTX 4080 / RTX 4090
30B	FP16	60	A100 (40GB) * 2
	INT8	40	L40 (48GB)
	INT4	24	RTX 4090
	INT2	16	T4 (16GB)
70B	FP16	120	A100 (80GB) * 2
	INT8	80	L40 (48GB) * 2
	INT4	48	L40 (48GB)
	INT2	32	RTX 4090
110B	FP16	200	H100 (80GB) * 3
	INT8	140	H100 (80GB) * 2
	INT4	72	A10 (24GB) * 3
	INT2	48	A10 (24GB) * 2

占位符

不同尺寸、不同精度 大模型预训练推荐GPU

- 其中RTX 4090可等价替换为RTX 3090；
- 其中A100可替换为A800（国内特供）；
- 其中L40可替换为L20（国内特供）；

模型尺寸	精度	显存需求 (GB)	推荐硬件配置
7B	AMP	120	A100 (40GB) * 3
	FP16	60	A100 (40GB) * 2
13B	AMP	240	A100 (80GB) * 3
	FP16	120	A100 (80GB) * 2
30B	AMP	600	H100 (80GB) * 8
	FP16	300	H100 (80GB) * 4
70B	AMP	1200	H100 (80GB) * 16
	FP16	600	H100 (80GB) * 8
110B	AMP	2000	H100 (80GB) * 25
	FP16	900	H100 (80GB) * 12

占位符

不同尺寸、不同精度 大模型**高效微调推荐GPU**

- 其中RTX 4090可等价替换为RTX 3090；
- 其中A100可替换为A800（国内特供）；
- 其中L40可替换为L20（国内特供）；

模型尺寸	精度	显存需求 (GB)	推荐硬件配置
7B	Freeze (FP16)	20	RTX 4090
	LoRA (FP16)	16	RTX 4090
	QLoRA (INT8)	10	RTX 4080
	QLoRA (INT4)	6	RTX 3060
13B	Freeze (FP16)	40	RTX 4090 / A100 (40GB)
	LoRA (FP16)	32	A100 (40GB)
	QLoRA (INT8)	20	L40 (48GB)
	QLoRA (INT4)	12	RTX 4090
30B	Freeze (FP16)	80	A100 (80GB)
	LoRA (FP16)	64	A100 (80GB)
	QLoRA (INT8)	40	L40 (48GB)
	QLoRA (INT4)	24	RTX 4090
70B	Freeze (FP16)	200	H100 (80GB) * 3
	LoRA (FP16)	160	H100 (80GB) * 2
	QLoRA (INT8)	80	H100 (80GB)
	QLoRA (INT4)	48	L40 (48GB)
110B	Freeze (FP16)	360	H100 (80GB) * 5
	LoRA (FP16)	240	H100 (80GB) * 3
	QLoRA (INT8)	140	H100 (80GB) * 2
	QLoRA (INT4)	72	A10 (24GB) * 3

占位符

不同使用场景下 推荐GPU配置方案

个人学习、小型科研团队

✓单台服务器参考配置

占位符

需求分析：

- 推理&微调： **7B-14B**
- 模型训练： **0.2B左右**
- 并发个数： **1-5**
- 数据量规模： **GB**
- 显存需求预估： **35G**

基础配置：

- GPU： **2080ti 22G * 2**
- CPU： **12代i5**
- 内存： **64G**
- 硬盘： **2T**
- 价格预估： **14000**

进阶配置：

- GPU： **3090 * 2**
- CPU： **12代i7**
- 内存： **64G**
- 硬盘： **2T**
- 价格预估： **25000**

中小型科研团队、初创公司

✓单台服务器参考配置

占位符

需求分析：

- 推理&微调： **14B-30B**
- 模型训练： 2B左右
- 并发个数： 5-20
- 数据量规模： TB
- 显存需求预估： **80G**

基础配置：

- GPU： **2080ti 22G * 4**
- CPU： Intel 至强W3
- 内存： 64G
- 硬盘： 2T
- 价格预估： **30000**

进阶配置：

- GPU： **3090 * 4**
- CPU： Intel 至强W5
- 内存： 128G
- 硬盘： 2T
- 价格预估： **47000**

大型科研团队、中大型公司

✓单台服务器参考配置

需求分析：


- 推理&微调：70B
- 模型训练：7B左右
- 并发个数：50-200
- 数据量规模：10TB
- 显存需求预估：140G

基础配置：

- GPU：L20 * 4
- CPU：Intel至强6133
- 内存：128G
- 硬盘：10T
- 价格预估：140000

进阶配置：

- GPU：A100 40G * 4
- CPU：Intel C621
- 内存：128G
- 硬盘：10T
- 价格预估：180000



>> 扫码添加**课程助教** <<
回复**LLM**领完整公开课资料

类别	内容
团队类型	个人学习 / 小型科研团队
需求分析	推理 & 微调：7B ~ 14B；模型训练：0.2B 左右；并发数：1 ~ 5；数据量：GB；显存需求：35GB
基础配置	GPU：2080 Ti (22GB) * 2；CPU：12代 i5；内存：64GB；硬盘：2TB；价格：14,000 元
进阶配置	GPU：3090 * 2；CPU：12代 i7；内存：64GB；硬盘：2TB；价格：25,000 元
团队类型	中小型科研团队 / 初创公司
需求分析	推理 & 微调：14B ~ 30B；模型训练：2B 左右；并发数：5 ~ 20；数据量：TB；显存需求：80GB
基础配置	GPU：2080 Ti (22GB) * 4；CPU：Intel 至强 W3；内存：64GB；硬盘：2TB；价格：30,000 元
进阶配置	GPU：3090 * 4；CPU：Intel 至强 W5；内存：128GB；硬盘：2TB；价格：47,000 元
团队类型	大型科研团队 / 中大型公司
需求分析	推理 & 微调：70B；模型训练：7B 左右；并发数：50 ~ 200；数据量：10TB；显存需求：140GB
基础配置	GPU：L20 (48GB) * 4；CPU：Intel 至强 6133；内存：128GB；硬盘：10TB；价格：140,000 元
进阶配置	GPU：A100 (40GB) * 4；CPU：Intel C621；内存：128GB；硬盘：10TB；价格：180,000 元

占位符

不同使用场景下 推荐GPU配置方案汇总



占位符

100+完整小时体系大课！零基础直达企业级Agent技术开发！

✓ 在线&开源大模型基础入门

✓ RAG、微调、Agent进阶技术实战


✓ 四大项企业级Agent开发实战！RAG系统搭建、市场分析Agent、智能客服、智能编程Agent项目实战！

12月班重磅新增

- ✓ 强化学习微调技术实战
- ✓ MateGen项目源码讲解
- ✓ GraphRAG项目实战

赠

- ✓ 讲师、助教双师答疑
- ✓ 课程项目简历项目模版
- ✓ 大模型岗面试八股文



>> 扫码回复大模型 <<
领完整课纲&抢超值优惠券